

UNIVERSIDADE DE MARÍLIA — UNIMAR
Curso de Algoritmos de Inteligência Artificial

DIABETESPREDICT: DIAGNÓSTICO DE DIABETES COM MACHINE LEARNING

Pima Indians Diabetes Database

Alan Uesugui Uemura — RA: 2084808
Julio Cesar Plaza — RA: 2046253

Grupo: 4

Marília — SP
2026

1 INTRODUÇÃO E OBJETIVO

O diabetes mellitus é uma doença crônica de alta prevalência mundial, caracterizada por níveis elevados de glicose no sangue. O diagnóstico precoce é fundamental para evitar complicações graves, como neuropatia, retinopatia e doenças cardiovasculares.

Este projeto tem como objetivo construir um modelo de classificação binária capaz de prever se uma paciente tem diabetes com base em medições clínicas simples, sem necessidade de exames invasivos adicionais. O trabalho utiliza o *Pima Indians Diabetes Database*, um conjunto de dados amplamente utilizado em pesquisas de Machine Learning aplicado à saúde.

A variável-alvo é *Outcome* (0 = não diabética, 1 = diabética). O critério de avaliação prioritário é o **Recall** — em contexto clínico, minimizar Falsos Negativos (diabetes não detectada) é mais crítico do que minimizar alarmes falsos, pois um diagnóstico perdido pode ter consequências graves.

2 DATASET

O *Pima Indians Diabetes Database* foi coletado pelo National Institute of Diabetes and Digestive and Kidney Diseases. Contém dados clínicos de 768 mulheres da população Pima Indian, com 8 variáveis preditoras numéricas e uma variável-alvo binária.

Tabela 1 — Variáveis do dataset e percentual de zeros suspeitos

Variável	Descrição	Zeros (%)
Pregnancies	Número de gestações	Não
Glucose	Glicose no plasma (mg/dL)	5 (0,7%)
BloodPressure	Pressão arterial diastólica (mmHg)	35 (4,6%)
SkinThickness	Espessura da pele — tríceps (mm)	227 (29,6%)
Insulin	Insulina sérica 2h (mu U/ml)	374 (48,7%)
BMI	Índice de Massa Corporal (kg/m ²)	11 (1,4%)
DiabetesPedigreeFunction	Função de história familiar de diabetes	Não
Age	Idade (anos)	Não
Outcome	Diagnóstico — variável-alvo (0/1)	—

Fonte: National Institute of Diabetes and Digestive and Kidney Diseases.

3 ANÁLISE EXPLORATÓRIA DOS DADOS

3.1 Distribuição das Classes

O dataset apresenta **desbalanceamento de classes**: 500 amostras não-diabéticas (65,1%) e 268 diabéticas (34,9%). Esse desequilíbrio é relevante porque um modelo que sempre prediz "não diabética" alcançaria 65% de acurácia sem aprender nada — reforçando a escolha de métricas como F1-Score, Recall e AUC-ROC em vez de acurácia simples.

3.2 Zeros Biologicamente Impossíveis

Colunas como *Insulin* (48,7% de zeros) e *SkinThickness* (29,6%) apresentam valores zero que são biologicamente impossíveis — indicando valores ausentes disfarçados. Remover essas linhas resultaria na perda de mais de 50% do dataset. Decisão adotada: substituir os zeros por NaN e imputar pela mediana dentro do Pipeline, calculando a mediana apenas com dados de treino (evitando *data leakage*).

3.3 Outliers

Outliers foram identificados via boxplots em todas as variáveis, com destaque para *Insulin* e *SkinThickness*. Em contexto médico, valores extremos podem representar casos reais e clinicamente relevantes — optou-se por preservá-los.

3.4 Correlações

Glucose ($r = +0,467$) e **BMI** ($r = +0,293$) são as variáveis com maior correlação com o diagnóstico de diabetes. Age e Pregnancies também apresentam correlação positiva moderada. O scatter plot confirma sobreposição considerável entre as classes — nenhuma variável isolada é suficiente para classificar com precisão, justificando o uso de modelos que combinam múltiplas features.

4 PRÉ-PROCESSAMENTO

Todos os modelos foram encapsulados em um Pipeline sklearn com três etapas sequenciais: (1) *SimpleImputer(strategy='median')* — substitui NaN pela mediana calculada no treino; (2) *StandardScaler()* — normaliza as features para média 0 e desvio padrão 1; (3) *Classificador* — Logistic Regression, GaussianNB ou RandomForest. O uso de Pipeline garante que medianas e parâmetros de

normalização sejam calculados exclusivamente com dados de treino, prevenindo *data leakage*.

A divisão treino/teste foi realizada com *test_size=0,2*, *random_state=42* e *stratify=y*, preservando a proporção de classes em ambos os conjuntos (614 amostras treino / 154 teste).

4.1 Tratamento do Desbalanceamento

Como melhoria em relação à entrega anterior, adicionou-se *class_weight='balanced'* na Regressão Logística e no Random Forest. Esse parâmetro ajusta automaticamente os pesos das classes inversamente proporcional à sua frequência, penalizando mais os erros na classe minoritária (diabéticas) durante o treinamento. O GaussianNB não suporta esse parâmetro — limitação do algoritmo.

5 MODELOS TREINADOS

Treinaram-se três algoritmos de classificação: Regressão Logística, Gaussian Naive Bayes e Random Forest. Para avaliação robusta, utilizou-se Validação Cruzada Estratificada com 5 folds, que preserva a proporção de classes em cada fold.

5.1 Otimização com GridSearchCV

O Random Forest foi selecionado para otimização por apresentar o melhor equilíbrio entre desempenho médio e estabilidade nos boxplots de validação cruzada. O GridSearchCV testou combinações dos hiperparâmetros *n_estimators* {50, 100, 200}, *max_depth* {3, 5, 8, None}, *min_samples_split* {2, 5, 10} e *min_samples_leaf* {1, 2, 4}, com *scoring=F1*.

Melhores hiperparâmetros encontrados: *max_depth=5*, *min_samples_leaf=2*, *min_samples_split=5*, *n_estimators=200*. Melhor F1-Score (CV): 0,7046.

6 ANÁLISE ESTATÍSTICA DAS VARIAÇÕES DE DESEMPENHO

Como melhoria em relação à entrega anterior, realizou-se uma análise estatística formal por meio do **Teste de Friedman** — teste não-paramétrico adequado para comparar múltiplos classificadores em múltiplos folds de validação cruzada, sem assumir normalidade dos dados.

Resultado obtido: Estatística = 9,9600, **p-value = 0,0189**. Como $p < 0,05$, há diferença estatisticamente significativa entre os modelos. O Random Forest Otimizado

foi o modelo mais estável (desvio padrão entre folds: $\pm 0,0051$) e de maior F1-Score médio no CV (0,7046).

7 RESULTADOS

Após validação cruzada e otimização, todos os modelos foram avaliados no conjunto de teste isolado (154 amostras nunca vistas durante o treinamento). Os resultados obtidos estão apresentados na Tabela 2.

Tabela 2 — Métricas comparativas no conjunto de teste (154 amostras)

Modelo	Acurácia	Precisão	Recall	F1-Score	AUC-ROC
Logistic Regression	0,7338	0,6032	0,7037	0,6496	0,8126
Gaussian NB	0,7013	0,5667	0,6296	0,5965	0,7646
Random Forest	0,7468	0,6596	0,5741	0,6139	0,8108
RF Otimizado	0,7338	0,5970	0,7407	0,6612	0,8213

Fonte: Elaborado pelos autores (2026).

7.1 Matrizes de Confusão

As matrizes de confusão evidenciam que o **Random Forest Otimizado** registrou apenas 14 Falsos Negativos (FN) — o menor valor entre todos os modelos —, enquanto o Random Forest sem otimização registrou 23 FN. Em diagnóstico clínico, minimizar FN é prioritário, pois diabetes não detectada pode evoluir para complicações graves.

7.2 Curvas ROC e Precision-Recall

As curvas ROC confirmam que o Random Forest Otimizado apresenta o maior AUC (0,8213), indicando melhor capacidade discriminativa geral. A curva Precision-Recall (AP = 0,6927) é especialmente útil neste problema desbalanceado, pois mostra o trade-off real: para detectar mais diabéticas (Recall alto), aceita-se mais alarmes falsos (Precisão menor).

7.3 Curvas de Aprendizado

As curvas de aprendizado mostram que nenhum modelo apresenta overfitting severo. A Regressão Logística apresenta curvas próximas e estáveis (baixo overfitting, possível underfitting leve). O Random Forest Otimizado beneficia-se de mais dados e tem o gap treino/validação controlado pelo `max_depth=5` otimizado.

7.4 Importância das Variáveis

O gráfico de importância confirma que **Glucose** (0,337) é a variável mais relevante, seguida por **BMI** (0,182), **Age** (0,126) e **Insulin** (0,115). **DiabetesPedigreeFunction** (0,076), **Pregnancies** (0,060), **SkinThickness** (0,053) e **BloodPressure** (0,051) contribuem menos, possivelmente pela maior sobreposição entre classes.

8 MODELO FINAL E JUSTIFICATIVA

O modelo final escolhido é o **Random Forest Otimizado**, com Pipeline completo: `SimpleImputer(median) → StandardScaler → RandomForestClassifier (max_depth=5, min_samples_leaf=2, min_samples_split=5, n_estimators=200, class_weight='balanced')`.

A justificativa baseia-se em três critérios: (1) maior F1-Score (0,6612) e AUC-ROC (0,8213) no conjunto de teste; (2) maior estabilidade entre os folds ($\text{std} = \pm 0,0051$); (3) menor número de Falsos Negativos (14), prioritário no contexto clínico.

8.1 Salvamento do Modelo

O modelo foi retreinado no dataset completo e salvo via `joblib.dump()` no formato `.joblib`. O Pipeline completo foi salvo, garantindo que a aplicação Streamlit aplique automaticamente a imputação, normalização e classificação ao receber novos dados. Arquivo: `model/modelo_final.joblib`.

9 APLICAÇÃO STREAMLIT

Foi desenvolvida uma aplicação web interativa com Streamlit que permite ao usuário inserir dados clínicos e obter uma predição imediata do modelo treinado. A aplicação contém:

- Formulário com os 8 campos de entrada compatíveis com as variáveis do modelo;
- Pré-processamento idêntico ao notebook (substituição de zeros por NaN antes da predição);
- Carregamento do modelo salvo via `joblib.load()` com cache (`@st.cache_resource`);
- Exibição do resultado com card colorido e probabilidade por classe;

- Tabela dos dados inseridos e interpretação clínica contextualizada;
- Aviso legal destacando o caráter acadêmico do projeto.

O deploy foi realizado via Streamlit Community Cloud. O link de acesso está disponível no README.md do repositório GitHub público do projeto.

10 CONCLUSÃO

O projeto demonstrou que é possível construir um classificador confiável para diagnóstico de diabetes utilizando dados clínicos simples. O Random Forest Otimizado com `class_weight='balanced'` e GridSearchCV apresentou o melhor desempenho geral, com bom equilíbrio entre Precisão e Recall.

As melhorias implementadas em relação à entrega anterior foram: (1) tratamento ativo do desbalanceamento via `class_weight='balanced'`; (2) análise estatística formal das variações de desempenho via Teste de Friedman; (3) salvamento completo do modelo e desenvolvimento da aplicação Streamlit.

10.1 Limitações

- Dataset pequeno (768 amostras) — limita a capacidade de generalização;
- População Pima Indian específica — pode não generalizar para outros grupos;
- Alto percentual de zeros em Insulin (48,7%) e SkinThickness (29,6%) — incerteza mesmo após imputação pela mediana;
- O modelo não substitui avaliação médica profissional.